



机器学习

Machine Learning



主讲人：张敏 清华大学长聘副教授



机器学习

MACHINE LEARNING-MIN ZHANG

Unit.10

深度学习基础（II）


*图片均来自网络或已发表刊物

目录

- 背景
- 多层感知机 (MLP)
- 卷积神经网络 (CNN)
- 序列神经网络
 - 循环神经网络 (RNN)
 - 长短期记忆网络 (LSTM)
 - 门控循环单位网络 (GRU)
- 应用举例

前向连接




- 前向网络
 - 没有反馈
- 循环网络
 - 层间反馈: 从输出层到输入层, 或者从隐层到输入层
 - 层内反馈



反馈连接可以使神经元的状态（包括输出）随时间变化，因为它们当前输入包含一些神经元上一个时间步的输出

动态系统

- 物理上的动态系统：




递归神经网络(Recurrent neural network,RNN)

- RNN 是一个动态系统
- 简单 RNN (The Elman network)

$$h_t = \mathcal{H}(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$$

$$y_t = W_{hy}h_t + b_y$$




记忆单元


- 缺点：
 - **梯度消失**: 更长的输入序列意味着更多的激活层相乘, 所以训练中梯度会趋近 0
 - 因此**解决长序列输入问题**是很难的

RNN

NN的模块A正在读取某个输入 x_i , 并输出一个值 h_i



=



循环使得信息可以从当前步传递到下一步

可看作是同一个神经网络的多次复制

词之间的依赖：“云飘在天上”

长距离依赖：“我在法国长大 我能讲一口流利的法语”


↓
LSTM

目录

- 背景
- 多层感知机 (MLP)
- 卷积神经网络 (CNN)
- 序列神经网络
 - 循环神经网络 (RNN)
 - 长短期记忆网络 (LSTM)
 - 门控循环单位网络 (GRU)
- 应用举例


From RNN

标准 RNN 中的重复模块包含单一的层，例如一个 tanh 层




To LSTM

LSTM 同样是这样的结构，但是重复的模块拥有一个不同的结构。



长短期记忆网络(Long short-term memory, LSTM)

- 将长期和短期的信息都考虑进来
- 设计了门 (gate) 来避免梯度消失
- 三个要点:
 - 什么应该被忘记?
 - 什么应该被记住?
 - 基于当前状态和输入, 输出应该是什么?



Neural Network
Layer

学习到的神经网络层

Pointwise
Operation

向量
操作

Vector
Transfer

从一个节点的输出
到其他节点的输入

Concatenate

向量的连接

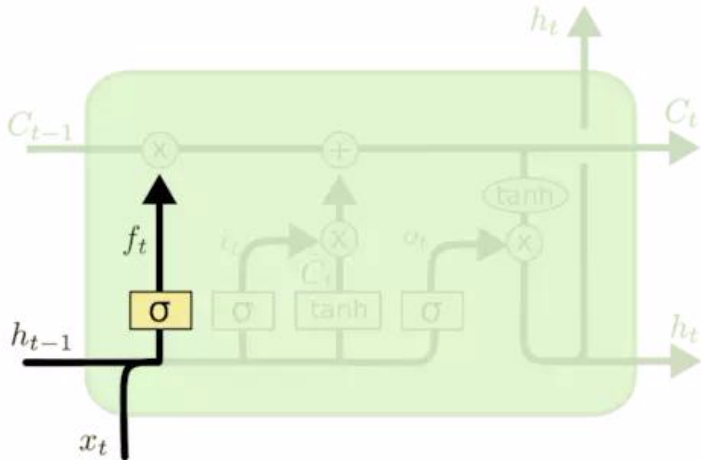
Copy

内容被复制, 然后
分发到不同的位置

Long short-term memory

LSTM 通过精心设计的“门”的结构来去除或增加信息到神经元状态的能力

- 第一部分: 什么应该被忘记 “忘记门”



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

门Gate: 一种让信息选择式通过的方法
包括sigmoid神经网络层,一个点积操作

Sigmoid 层输出 0 到 1 之间的数值, 描述每个部分有多少量可以通过。
0 代表“不许任何量通过”, 1 代表“允许任意量通过”

Long short-term memory

- 第二部分: 什么应该被记住


- 计算新的输入

sigmoid 层(“输入门层”) 决定
我们将要更新什么值


tanh 层创建一个新的候选值向量

- 更新当前记忆单元

更新旧神经元状态, C_{t-1} 更新为 C_t




$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Long short-term memory

- 第三部分: 计算输出



$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

sigmoid 层用来确定神经元状态的哪个部分将被输出
把神经元状态通过 \tanh 进行处理（得到一个在-1到 1 之间的值）
并将它与 sigmoid 门的输出相乘

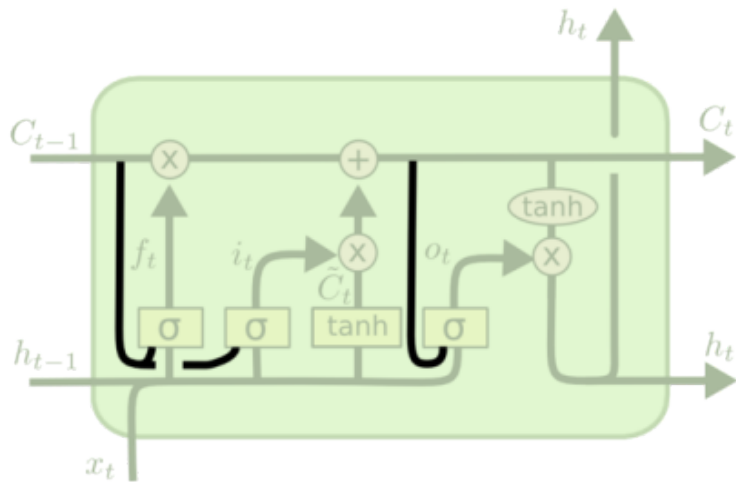
- 缺点: 参数太多, 可能导致过拟合

目录

- 背景
- 多层感知机 (MLP)
- 卷积神经网络 (CNN)
- 序列神经网络
 - 循环神经网络 (RNN)
 - 长短期记忆网络 (LSTM)
 - 门控循环单位网络 (GRU)
- 应用举例

LSTM 的变体 (1)


peephole connection [Gers & Schmidhuber (2000)]



$$f_t = \sigma(W_f \cdot [C_{t-1}, h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [C_{t-1}, h_{t-1}, x_t] + b_i)$$


$$o_t = \sigma(W_o \cdot [C_t, h_{t-1}, x_t] + b_o)$$




增加了“窥视孔连接”，即我们让门层也会接受神经元状态的输入
很多工作中只加入部分而非所有都加

LSTM 的变体 (2)

整合输入门和遗忘门 (coupled input gate and forget gate)




$$C_t = f_t * C_{t-1} + (1 - f_t) * \tilde{C}_t$$



之前是分开确定什么忘记和需要添加什么新的信息，现在一同做出决定
只在要输入到当前位置时忘记；只输入新的值到已经忘记旧的信息的状态

LSTM变体 (3) : 门控循环单元网络

- Gated recurrent unit, GRU [Cho, et al. (2014)]
- 将输入门和遗忘门结合成一个单一的更新门
- C_t 被设为 h_t (混合了输出状态和隐藏状态, 只有一个输出向量)
- 参数更少




$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$



目录

- 背景
- 多层感知机 (MLP)
- 卷积神经网络 (CNN)
- 序列神经网络
 - 循环神经网络 (RNN)
 - 长短期记忆网络 (LSTM)
 - 门控循环单位网络 (GRU)
- 应用举例

人脸识别



Coo d'Este

Melina Kanakaredes



Elijah Wood

Stefano Gabbana



Jim O'Brien

Jim O'Brien


Model	Accuracy (%)
DeepFace (2014)	97.25
DeepID (2014)	97.45
DeepID2 (2014)	99.15
DeepID2+ (2014)	99.47
DeepID3 (2014)	99.53
FaceNet (2015)	99.63

图片风格转换




Created by Prisma 20

医疗图像分析



Kaggle Data Science
Bowl 2016



Kaggle Data Science
Bowl 2017

语音识别

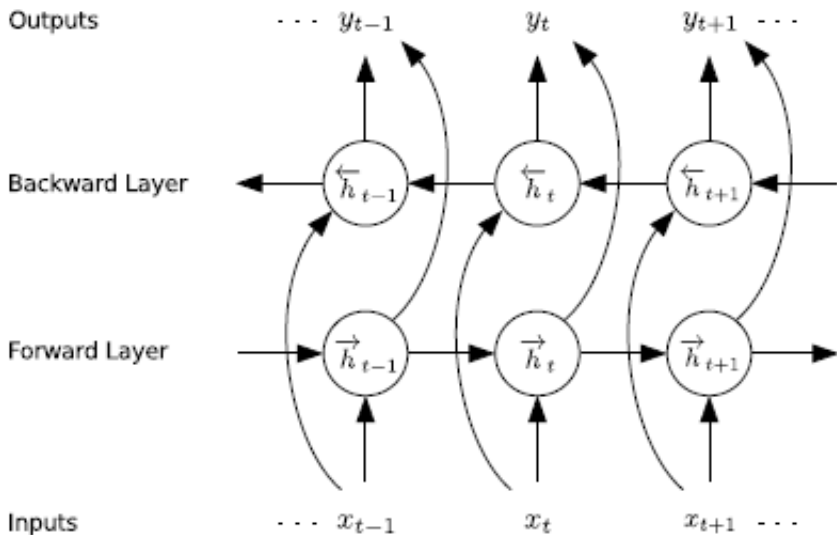
- 双向 RNN

$$\vec{h}_t = \mathcal{H}(W_{x\vec{h}}x_t + W_{\vec{h}\vec{h}}\vec{h}_{t-1} + b_{\vec{h}})$$

$$\overleftarrow{h}_t = \mathcal{H}(W_{x\overleftarrow{h}}x_t + W_{\overleftarrow{h}\overleftarrow{h}}\overleftarrow{h}_{t+1} + b_{\overleftarrow{h}})$$

$$y_t = W_{\vec{h}y}\vec{h}_t + W_{\overleftarrow{h}y}\overleftarrow{h}_t + b_y$$

- 结合 BRNNs 和 LSTM 得到双向 LSTM
- 每个时间步 t 在输出层用 Softmax 函数 (大小为 $K+1$)
 - K 个音素加上一个不输出的单元



Graves et al., 2013

图片摘要



A boy is riding a bike besides a lake.



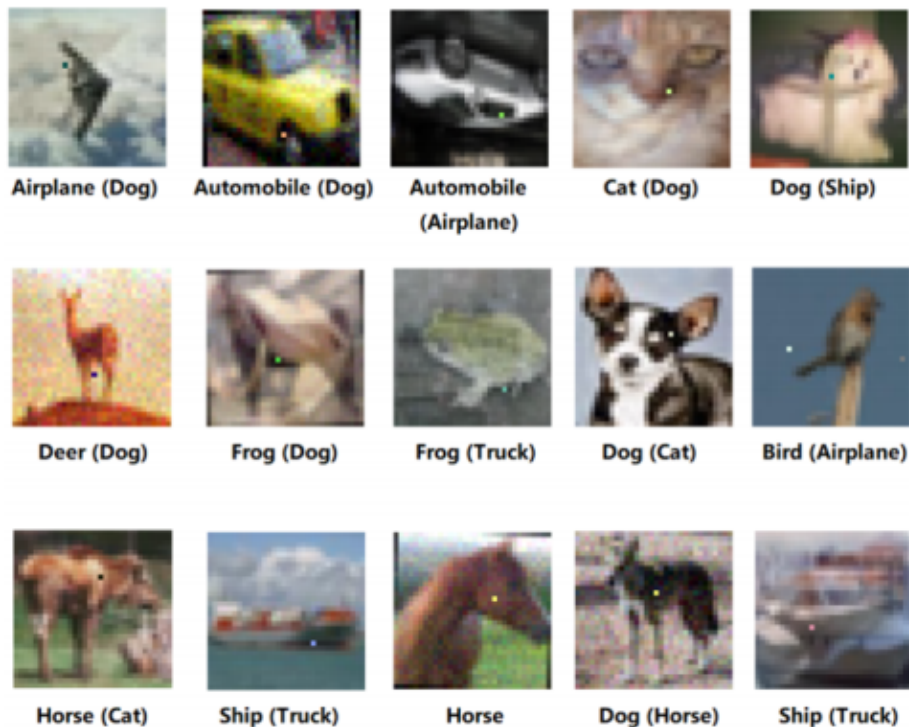
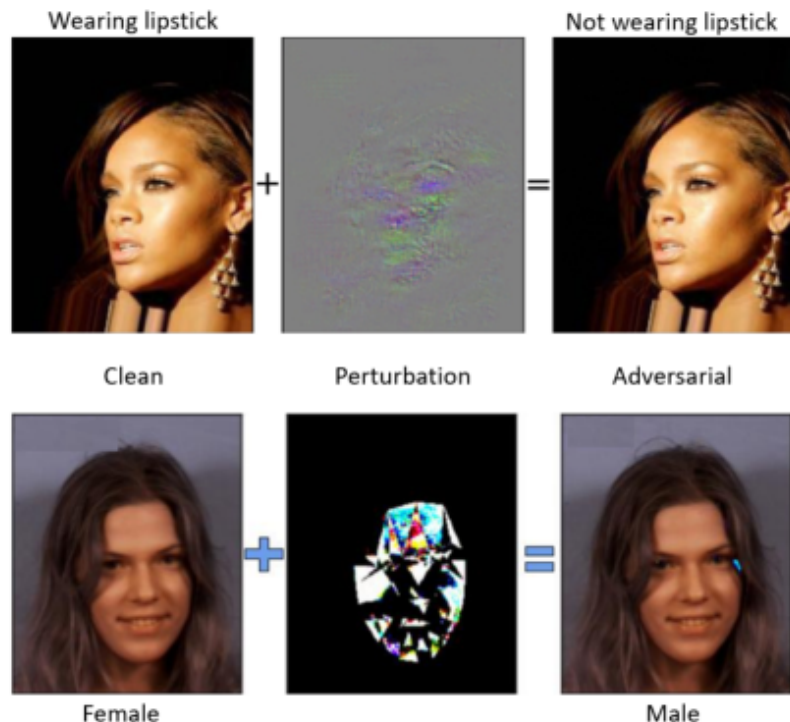
Two kids are making pizza.

总结

- 深度学习在很多实际问题上都取得了不错的结果
- 可能是处理大量数据的一个较好选择
- 模型太大可能是个问题
 - 并行计算
- 理论基础欠缺
- 缺少可解释性
- 对恶意攻击不鲁棒

深度神经网络攻击举例

1 pixel adversarial attack



<https://arxiv.org/abs/1710.08864>

在线资源

- 网站: <http://deeplearning.net/>
 - A reading list
 - Software
 - Datasets
 - Tutorials and demos
- 编程工具
 - Theano @ University of Montreal
 - Caffe @ UC Berkley
 - Tensorflow by Google
 - Torch by Facebook
 - Deeplearning4j

深度学习基础（总结）

- 背景
- 多层感知机（MLP）
- 卷积神经网络（CNN）
- 序列神经网络
 - 循环神经网络（RNN）
 - 长短期记忆网络（LSTM）
 - 门控循环单位网络（GRU）
- 应用举例
- 总结及在线资源